


Predição neural

- Estratégia preditiva utilizando uma RNA
- Predição x interpolação
- Análise da possibilidade de equalização de canais de fase não mínima utilizando somente estatísticas de 2ª ordem

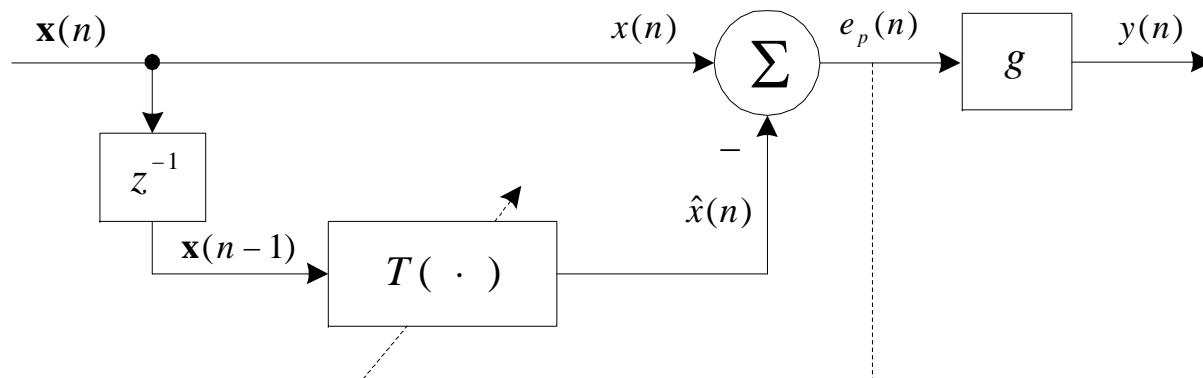


Predição neural

- Predição linear
 - Utilização de várias entradas: separação linear
 - Equalização: canais de fase mínima (predição direta) ou máxima (predição reversa ou retropredição)
 - Processo de super-branqueamento: independência dos símbolos transmitidos

Predição neural

- Predição linear(cont.)



- Erro de predição:

$$e_p(n) = x(n) - \hat{x}(n)$$



Predição neural

- Predição linear(cont.)

$$\bar{x}(n) = a(n)f_0 + a(n-1)f_1 + \cdots + a(n-N+1)f_{N-1}$$

$$\bar{x}(n-1) = a(n-1)f_0 + a(n-2)f_1 + \cdots + a(n-N+2)f_{N-1}$$

$$\bar{x}(n-2) = a(n-2)f_0 + a(n-3)f_1 + \cdots + a(n-N+3)f_{N-1}$$

$$\vdots$$
$$\vdots$$
$$\vdots$$
$$\vdots$$



Predição neural

■ Predição linear(cont.)



$$\bullet e_p(n) = \underbrace{a(n)f_0 + \dots + a(n-N+1)f_{N-1}}_{x(n)} + b(n) \\ - \underbrace{x(n-1)p_1 + x(n-2)p_2 + \dots + x(n-M)p_M}_{\hat{x}(n)}$$

■ Para $M = N - 1 = 2$

$$\bullet e_p(n) = a(n)f_0 + a(n-1)[f_1 - f_0p_1] + a(n-2)[f_2 - f_1p_1 - f_0p_2] \\ - a(n-3)[f_2p_1 + f_1p_2] - a(n-4)f_2p_2 + b(n) + b(n-1)p_1 + b(n-2)p_2$$

Predição neural

- Predição x interpolação:
 - Busca de uma superfície de interpolação capaz de separar as diferentes classes





Predição neural

- Predição x interpolação:
 - É possível implementar uma função de interpolação não linear para equalização baseado em uma estrutura preditiva com ***apenas uma entrada***.

$$e_p(n) = x(n) - \hat{x}(n) \qquad \hat{x}(n) = \Psi(\mathbf{x}(n-1))$$

$$e_p(n) = \underbrace{a(n)f_0 + a(n-1)f_1 + \cdots + a(n-N+1)f_{N-1} + b(n)}_{x(n)} - \underbrace{\Psi(x(n-1), x(n-2), x(n-3), \cdots)}_{\hat{x}(n)}$$




Predição neural

- Predição x interpolação:
 - Toda informação necessária para retirar a redundância está contida em $x(n-1)$, logo:

$$\begin{aligned}\Psi(a(n-1)f_0 + a(n-2)f_1 + \cdots + a(n-N+2)f_{N-1} + b(n-1)) \\ = a(n-1)f_1 + a(n-2)f_2 + \cdots + a(n-N+1)f_{N-1} + b(n)\end{aligned}$$


- então o erro de predição será dado por:

$$e_p(n) = x(n) - \Psi(x(n-1))$$



Predição neural

- Preditor neural: equalização de canais de fase não mínima






Predição neural

- Preditor neural (cont.):
 - Função capaz de realizar a separação das classes pode ser escrita como:

$$\Psi_{RN}(x, \theta, \beta) = \sum_i \beta_i \cdot \text{sgn}(x - \theta_i)$$

- A estrutura que implementa a função será denominada de “**Neural Predictive Structure**” (NPS)

Predição neural





Predição neural

- NPS:
 - Rede MLP com uma entrada e uma camada escondida
 - Função de ativação: $\phi_{\text{NPS}}(.) = \text{sgn}(.)$
 - Aprendizado:
 - Capacidade de aprender os locais das transições rápidas
 - Algoritmo de localização do *bias* (θ_i)
 - Distribuição de probabilidade do sinal recebido



Predição neural

- fdp do sinal recebido:
 - Composição de gaussianas
 - Centradas nos estados do canal
 - Variância σ_b^2



Predição neural

- fdp do sinal recebido (cont.):
 - O sinal na saída do canal modelado por:

$$x(n) = \bar{x}(n) + b(n)$$

em que $\bar{x}(n) = \mathbf{a}^T(n)\mathbf{f}$ e $b(n)$ apresenta uma fdp dada por

$$p(b(n)) = \frac{1}{\sqrt{2\pi\sigma_b^2}} \exp\left(-\frac{|b(n)|^2}{2\sigma_b^2}\right)$$

sendo $b(n) = x(n) - \bar{x}(n)$

$$p(x(n)) = \frac{1}{\sqrt{2\pi\sigma_b^2}} \sum_{i=1}^s \exp\left(-\frac{|x(n) - \mathbf{a}_i^T \mathbf{f}|^2}{2\sigma_b^2}\right) \Pr(\mathbf{a}(n) = \mathbf{a}_i)$$




Predição neural

- Aprendizado da NPS:
 - Localização correta dos bias
 - Algoritmo auto organizado
 - Capacidade de encontrar os *vales* entre as gaussianas que compõem a fdp do sinal recebido
- Ajuste dos parâmetros β_i
 - Algoritmo supervisionado
 - Adaptação clássica de parâmetros lineares

Predição neural

- Algoritmo auto organizado
 - Princípio: medida de similaridade de funções.
 - Função utilizada: função módulo ($N(x, d)$).
 - *Contraste*:




Predição neural

- Algoritmo auto organizado

- Funcional: $J_1(d) = \int p(x) \cdot N(x, d) dx$
 $J_1(d) = E\{N(x, d)\}$

- Resultados:






Predição neural

- Algoritmo auto organizado
 - Melhorar *estreiteza* da função: $\ln(N(x, d))$
 - Funcional: $J_2(d) = \int p(x) \cdot \ln(N(x, d)) dx$
$$J_2(d) = E\{\ln(N(x, d))\}$$
 - Corresponde à divergência de Kullback-Leibler (KLD) eliminando-se os termos independentes de $N(x, d)$

Predição neural

- Algoritmo auto organizado

- Resultados:



- **“Self-Organized for Finding Valleys Algorithm” (SOFVA)**



Predição neural

- Algoritmo supervisionado: dois casos
 - Minimização do erro de predição (MEP)

$$E\left\{|e_p(n)|^2\right\}$$

Denominada NPS-MPE

- Critério do módulo constante (CMC)


$$E\left\{\left(|y(n)|^2 - R_2\right)^2\right\}$$

Denominada NPS-CMC

Predição neural


- Simulações:


- Canais de fase mínima: $\mathbf{f}_1 = [1 \quad 0.6 \quad 0.2]^T$



Predição neural


- Canais de fase mínima: $\mathbf{f}_1 = [1 \quad 0.6 \quad 0.2]^T$
 - Melhoria com inicialização LS






Predição neural


- Superfícies de interpolação $\mathbf{f}_1 = [1 \quad 0.6 \quad 0.2]^T$



NPS-MPE



NPS-MPE-LS




NPS-CMC

SNR = 40 dB


Predição neural


- Canais de fase mínima: $\mathbf{f}_2 = [1 \ 0.8 \ 0.4]^T$



Predição neural


- Canais de fase mínima: $\mathbf{f}_2 = [1 \quad 0.8 \quad 0.4]^T$
 - Inicialização LS






Predição neural


- Superfícies de separação $\mathbf{f}_2 = [1 \quad 0.8 \quad 0.4]^T$



NPS-MPE



NPS-MPE-LS





NPS-CMC

SNR = 40 dB

Predição neural


- Canais de fase não mínima: $\mathbf{f}_3 = [0.5 \quad 1 \quad -0.6]^T$






Predição neural

- Superfícies de interpolação:



NPS-MPE




NPS-CMC

SNR = 40 dB

Predição neural

- Canais de fase não mínima: $\mathbf{f}_4 = [0.4 \ 1 \ 0.4]^T$





Predição neural

- Limites:

- Ruído
- Posição dos zeros do canal

- Características

- Possibilidade de determinação do número ótimo (NO) de neurônios para uma entrada
- No. entradas \uparrow , No. Neurônios $<$ NO
- Possibilidade de extensão para casos não estacionários